

MUCHA

Model uczenia CHwytający Anomalie

Martyna Sadowska

Jan Taran

Kacper Tomczyk

Wydział Matematyki i Nauk Informatycznych
Politechnika Warszawska

10 czerwca 2026

Cel projektu

MUCHA - Model uczenia CHwytający Anomalie


Projekt ma na celu stworzenie systemu detekcji anomalii sieciowych opartego na uczeniu maszynowym, zdolnego do automatycznego identyfikowania zarówno znanych zagrożeń, jak i nowych, nieznanych typów cyberataków.

- **Klasyfikacja binarna:** ruch normalny vs. atak
- **Podejście:** wykrywanie odchyleń od normy (outlier detection)
- **Rezultat:** aplikacja desktopowa z graficznym interfejsem użytkownika umożliwiającą analizę plików CSV z ruchem sieciowym

Anomalie sieciowe

Czym jest anomalia?

- Odchylenie od typowego wzorca ruchu sieciowego
- Może świadczyć o:
 - cyberataku (DoS, skanowanie portów)
 - awarii sprzętu
 - nieautoryzowanym dostępie
- Kluczowe: wykryć anomalię *zanim* dojdzie do szkód



Rysunek 1: Anomalia w szeregu czasowym

Motywacje

- **Cyfryzacja społeczeństwa** - usługi sieciowe generują ogromne wolumeny danych w czasie rzeczywistym
- **Niemożliwość ręcznej analizy** - administrator sieci nie jest w stanie przeglądać milionów pakietów dziennie
- **Niewystarczalność tradycyjnych metod** - systemy oparte wyłącznie na sygnaturach nie radzą sobie z nowymi typami ataków
- **Rosnące koszty incydentów** - skutki cyberataku obejmują straty finansowe, wyciek danych i utratę reputacji
- **Potrzeba automatyzacji** - model ML może analizować ruch w czasie rzeczywistym i zgłaszać podejrzane zdarzenia bez udziału człowieka

Automatyczna detekcja anomalii to nie luksus - to konieczność.



Wybrane rodzaje ataków sieciowych

Na podstawie zbioru KDDCUP'99 wyróżniamy cztery główne kategorie:

Kategoria	Opis
DoS	Denial of Service - wyczerpanie zasobów serwera poprzez masowe żądania; cel: niedostępność usługi
Probe	Skanowanie sieci w celu identyfikacji podatnych hostów i otwartych portów; wstęp do głębszego ataku
R2L	Remote to Local - próba nieautoryzowanego dostępu z zewnątrz sieci do zasobów wewnętrznych
U2R	User to Root - eskalacja uprawnień; atakujący z prawami zwykłego użytkownika próbuje uzyskać dostęp root

Istniejące rozwiązania - open source

Snort

- Darmowy IDS/IPS
- Wykrywanie na bazie sygnatur
- Standard branżowy

Suricata

- Wielowątkowy IDS/IPS
- Kompatybilny z Snortem
- Wyższy throughput

Zeek

- Analiza behawioralna
- Generuje logi przepływów
- Elastyczny framework

Zalety:

- Darmowe i transparentne
- Duże społeczności i wsparcie
- Możliwość dostosowania reguł

Wady:

- Tylko wykrywanie sygnaturowe
- Bezsilne wobec nowych ataków
- Wymagają częstej aktualizacji

Istniejące rozwiązania - komercyjne

Darktrace

- AI behawioralne
- Uczy się *normalności* sieci
- Automatyczna odpowiedź

Cisco Secure IPS

- Integracja z Cisco
- Sygnatury + ML
- Dla dużych firm

Palo Alto NGFW

- Next-Gen Firewall
- Inspekcja głęboka
- Chmurowa analiza

Zalety:


- Analiza behawioralna - AI
- Skuteczne wobec nowych zagrożeń
- Wsparcie techniczne producenta

Wady:

- Architektura *czarnej skrzynki*
- Bardzo wysokie koszty licencji
- Uzależnienie od ekosystemu

Proponowane rozwiązanie - pipeline

- 1 Pozyskanie danych** - zbiór CICIDS2017 w formacie CSV
- 2 Ekstrakcja i selekcja cech** - redukcja 84 → 15–20 cech
- 3 Trening modelu** - XGBoost z tunowaniem hiperparametrów
- 4 Ewaluacja** - metryki Precision, Recall, F1-Score
- 5 Wdrożenie** - aplikacja desktopowa z GUI



Rysunek 2: Diagram potoku przetwarzania danych

Zbiór danych - CICIDS2017

Canadian Institute for Cybersecurity Intrusion Detection Dataset 2017

Zbiór stworzony przez University of New Brunswick poprzez symulację rzeczywistej sieci biurowej z generowaniem różnych typów ataków.

Charakterystyka:

- $\approx 2\,830\,743$ rekordów
- **84** cechy opisujące przepływy sieciowe
- Pliki CSV (≈ 900 MB łącznie)
- Oryginalne pliki PCAP: ≈ 50 GB

Dane pobierane automatycznie przez `download_data.py` z platformy Kaggle ([kagglehub](https://www.kaggle.com/c/cicids2017)).

Najczęstsze ataki w zbiorze:

- DDoS / DoS
- Port Scan
- Infiltration
- Brute Force / Bot

Selekcja i ekstrakcja cech

Problem

84 cechy to nadmiar - wiele z nich jest skorelowanych lub nieprzydatnych. Prostszy model jest szybszy i mniej podatny na przeuczenie.

Cel: redukcja do **15–20 kluczowych cech** uniwersalnych dla różnych środowisk sieciowych. **Przykłady wybranych cech:**

- Czas trwania sesji (Flow Duration)
- Długości pakietów (min, max, średnia, odchylenie)
- Liczba pakietów na jednostkę czasu (Packets/s)
- Rozkład flag TCP (SYN, ACK, FIN, RST)
- Proporcja danych przesłanych w obu kierunkach

Cechy wybierane na podstawie analizy ważności cech modelu XGBoost.

Model uczenia maszynowego - XGBoost

Dlaczego XGBoost?

- Gradient Boosting - ansambel drzew decyzyjnych
- Bardzo wysoka dokładność
- Wbudowana obsługa brakujących danych
- Szybka predykcja - kluczowe dla sieci

Podział danych

- 80% - zbiór treningowy
- 20% - zbiór testowy
- Stratyfikacja klas

Preprocessing

- float64 → float32
- int64 → int32
- Usunięcie $\pm\infty$ i NaN

Problem niezbalansowanych klas

Problem

W rzeczywistym ruchu sieciowym ataki stanowią **ułamek procenta** całego ruchu. Model naiwny, który zawsze przewiduje klasę *normalną*, może osiągać **accuracy** $> 99\%$ - i jednocześnie być bezużyteczny dla bezpieczeństwa.

Rozwiązanie: metryka F1-Score

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

F1-Score nagradza model za **prawidłowe wykrywanie ataków**, a nie za zgadywanie klasy większościowej.

Problem przetwarzania plików PCAP

Kontekst

Pliki PCAP zawierają surowe dane pakietów sieciowych. Narzędzie **CICFlowMeter** służy do ekstrakcji statystyk przepływów z plików PCAP do formatu CSV.

Napotkane konflikty:

- Niezgodność między bibliotekami analizy pakietów (scapy, npcap) a sterownikami Windows
- CICFlowMeter wymaga środowiska Linuxowego z tcpdump
- Próba integracji przez tshark - ograniczona lista pól nie odpowiada cechom modelu

Przyjęte rozwiązanie

Aplikacja pracuje wyłącznie na gotowych plikach **CSV** zgodnych ze schematem CICIDS2017.

Wyniki modelu

Metryki na zbiorze
testowym:

Metryka	Wartość
Accuracy	0,9600
Precision	0,9800
Recall	0,8200
F1-Score	0,8944

Zbiór testowy: 565 149
rekordów
(20% z 2 830 743, podział
stratyfikowany)

Interpretacja:

- **Precision = 0,98** - niemal każde zgłoszone zagrożenie jest rzeczywistym atakiem (mało fałszywych alarmów)
- **Recall = 0,82** - model wykrywa 82% wszystkich ataków
- **F1 = 0,89** - dobra równowaga między precyzją a czułością
- Wynik zadowalający biorąc pod uwagę znaczne niezbalansowanie klas

Demo aplikacji

Detektor Anomalii Sieciowych

Autrzy: Martyna Sadowska, Jan Taran, Kacper Tomczyk

Destination Port	Flow Duration	Total Fwd Packets	al Backward Pack	Length of Fwd Pa	Length of Bwd Pa	d Packet Length h	d Packet Length h	i Packet Length M	i Packet Length M	d Packet Length S	d Packet Length h	i Packet Length M	i Packet Length M	Flow Bytes/h
33308	13	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	2384615.385
33306	3	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	10300000.0
40306	3	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	10300000.0
40331	47	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	659574.4681
40329	1	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	31000000.0
38819	48	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	645833.3333
57685	4	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	7750000.0
55545	4	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	7750000.0
43666	4	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	7750000.0
43681	3	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	10300000.0
43680	3	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	10300000.0
43653	48	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	645833.3333
44056	4	2	0	31	0	31	0	15.5	21.92031022	0	0	0.0	0.0	7750000.0
44212	4	2	0	12	0	6	6	6.0	0.0	0	0	0.0	0.0	3000000.0
80	4141015	4	0	24	0	6	6	6.0	0.0	0	0	0.0	0.0	5.795680528
80	4138913	4	0	24	0	6	6	6.0	0.0	0	0	0.0	0.0	5.798623938
80	4137904	5	0	30	0	6	6	6.0	0.0	0	0	0.0	0.0	7.250047367
80	4138020	4	0	24	0	6	6	6.0	0.0	0	0	0.0	0.0	5.799875303
80	4142405	4	0	24	0	6	6	6.0	0.0	0	0	0.0	0.0	5.793735765

Importuj CSV Znajdź anomalie

Rysunek 3: Główny widok aplikacji *Detektor Anomalii Sieciowych*

Wnioski

- 1 ML wymaga więcej niż dobrego modelu** - obsługa niezbalansowanych klas (wybór właściwej metryki) jest równie istotna co architektura modelu.
- 2 Podejście bottom-up się sprawdziło** - metodyczne przejście od analizy problemu, przez przegląd istniejących rozwiązań, do implementacji pozwoliło uniknąć wielu pułapek.
- 3 XGBoost jest skuteczny i praktyczny** - osiąga $F1 = 0,89$ przy bardzo szybkim czasie predykcji, co jest kluczowe w zastosowaniach sieciowych.
- 4 Pragmatyczne decyzje inżynierskie** - rezygnacja z obsługi PCAP na rzecz gotowych CSV skróciła czas implementacji bez istotnej utraty funkcjonalności.
- 5 Obecne rozwiązanie osiąga wysoką dokładność** w identyfikacji anomalii sieciowych na zbiorze CICIDS2017.

Kierunki dalszego rozwoju

Możliwe rozszerzenia projektu

- **Analiza w czasie rzeczywistym** - integracja z przechwytywaniem pakietów na żywo (np. przez libpcap na Linuksie)
- **Klasyfikacja wieloklasowa** - identyfikacja nie tylko czy to atak, ale *jakiego rodzaju* (DoS, Probe, R2L, U2R)
- **Integracja z alertami systemowymi** - powiadamianie administratora w momencie wykrycia anomalii (e-mail, webhook, SIEM)
- **Periodyczne re-trenowanie modelu** - cyberbezpieczeństwo jest dziedziną dynamiczną; model musi ewoluować wraz z nowymi typami ataków
- **Wyjaśnialność (XAI)** - wskazywanie, które cechy zadecydowały o klasyfikacji jako atak

Literatura I

- [1] Akvelon, "Materiały graficzne – schemat poglądowy anomalii," <https://akvelon.com/wp-content/uploads/2020/11/Image-4.jpg>, 2020, dostęp: 26.03.2026.
- [2] M. Tavallaei, E. Bagheri, W. Lu, and A. Ghorbani, "A detailed analysis of the KDD CUP 99 data set," in *IEEE Symposium on Computational Intelligence for Security and Defense Applications (CISDA)*, 2009, pp. 1–6.
- [3] M. Roesch, "Snort: Lightweight intrusion detection for networks," in *Proceedings of the 13th USENIX Conference on System Administration (LISA)*, Seattle, WA, USA, 1999, pp. 229–238.
- [4] S. A. R. Shah and B. Issac, "Performance comparison of intrusion detection systems and application of machine learning to Snort system," *Future Generation Computer Systems*, vol. 80, pp. 157–170, 2018.

Literatura II

- [5] V. Paxson, "Bro: a system for detecting network intruders in real-time," *Computer Networks*, vol. 31, no. 23–24, pp. 2435–2463, 1999.
- [6] Darktrace, "The enterprise immune system: The World's First Autonomous Cyber AI Platform," Darktrace, Cambridge, UK, Whitepaper, 2021.
- [7] Cisco Systems, "Cisco next-generation intrusion prevention system (NGIPS)," Cisco Systems, San Jose, CA, USA, Technical Data Sheet, 2022.
- [8] Palo Alto Networks, "Next-generation firewall architecture overview," Palo Alto Networks, Santa Clara, CA, USA, Technical Report, 2022.
- [9] Capterra, "Profil i recenzje oprogramowania Snort," <https://www.capterra.ca/software/1010620/snort>, 2026, dostęp: 08.04.2026.

Literatura III

- [10] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward generating a new intrusion detection dataset and intrusion traffic characterization," in *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*, 2018, pp. 108–116.
- [11] N. Moustafa and J. Slay, "UNSW-NB15: a comprehensive data set for network intrusion detection systems," in *2015 Military Communications and Information Systems Conference (MilCIS)*, Sydney, Australia, 2015, pp. 1–6.
- [12] A. H. Lashkari, G. Draper-Gil, M. S. I. Mamun, and A. A. Ghorbani, "Characterization of Tor traffic using time based features," in *Proceedings of the 3rd International Conference on Information Systems Security and Privacy (ICISSP)*, Porto, Portugal, 2017, pp. 253–262.